

BIG DATA & MACHINE LEARNING

HISTOGRAMAS, KERNELS & MÉTODOS NO SUPERVISADOS USANDO LA EPH

Equipo 23: Brian Rios, Francisco Borghetti, Leandro Mariniello

Parte I: Creación de variables, histogramas, kernels y resumen de la base de datos final 1

Ejercicio 1) 1

Ejercicio 2) 2

Ejercicio 3) 2

Ejercicio 4) 3

Ejercicio 5) 3

Parte II: Métodos No Supervisados 4

Ejercicio 1) 4

A. PCA..... 5

Ejercicio 2) 5

Ejercicio 3) 6

Ejercicio 4) 6

B. Cluster 7


Ejercicio 5) a)..... 7

Ejercicio 5) b)..... 8

Ejercicio 6) 8

Parte I: Creación de variables, histogramas, kernels y resumen de la base de datos final

Ejercicio 1)




Trabajo práctico N°3

En el Panel A se observa que la distribución de edades es relativamente homogénea hasta los 40 años, con mayor concentración entre los 10 y 40 años, y una caída progresiva en las frecuencias a partir de los 50. En el Panel B, las distribuciones kernel muestran que los desocupados tienden a concentrarse en edades más tempranas (con un pico en torno a los 20 años), mientras que los ocupados se concentran principalmente entre los 30 y 50 años. Esto sugiere una mayor presencia de jóvenes en situación de desocupación y una mayor estabilidad laboral en edades intermedias. Ambas curvas se vuelven más planas en edades avanzadas, reflejando menor participación en el mercado laboral.



Ejercicio 2)

	valor
count	7104
mean	8,778012387
std	4,718470354
min	0
25%	7
50%	8
75%	12
max	24



El gráfico muestra la distribución de los años de educación formal alcanzados por los individuos encuestados en el primer trimestre de 2004 y 2024 en el Gran Buenos Aires. La mayoría de los individuos tienen entre 7 y 12 años de educación, lo cual corresponde aproximadamente a la primaria y el secundario completos. Se observa una concentración importante en los 12 años, lo que sugiere que muchos completaron el nivel secundario. También hay una cola derecha que refleja a quienes alcanzaron niveles terciarios o universitarios. Algunos valores extremos (como más de 20 años de educación) podrían corresponder a estudios de posgrado o errores en la codificación y merecen una revisión adicional.

Ejercicio 3)



El gráfico de la variable salario_semanal muestra una distribución sesgada a la derecha, con una concentración de salarios bajos y algunos valores extremos más altos. En el panel A, el histograma refleja que muchos salarios semanales están en el rango más bajo, mientras que hay pocos casos con salarios elevados. En el panel

B, la distribución de kernel para los ocupados muestra una concentración en salarios más altos en comparación con los desocupados, quienes tienen una distribución más dispersa, lo que indica que los desocupados tienen una mayor variabilidad en los ingresos.

Ejercicio 4)

	valor
mean	39,80823364
std	18,92632285
min	2
median	40
max	133

- El promedio de horas trabajadas a la semana es de aproximadamente 39.81 horas.
- La desviación estándar de 18.93 horas indica una dispersión considerable en las horas trabajadas.
- El mínimo de horas trabajadas es 2 horas.
- La mediana (percentil 50) es de 40 horas, lo cual sugiere una jornada laboral típica.
- El máximo de horas trabajadas es de 133 horas, indicando casos extremos de jornadas muy extensas.

La variable horastrab, que representa el total de horas trabajadas sumando la ocupación principal y otras ocupaciones, muestra un promedio de aproximadamente 40 horas semanales, lo cual es coherente con una jornada laboral estándar. La mediana también se encuentra en 40 horas, lo que indica que al menos la mitad de los encuestados se ajusta a esta modalidad. Sin embargo, la desviación estándar relativamente alta (18.92 horas) refleja una gran heterogeneidad, evidenciando la presencia tanto de trabajadores con empleos reducidos como de quienes trabajan jornadas extendidas. El mínimo de 3 horas sugiere actividades marginales o muy parciales, mientras que el máximo de 133 horas indica casos extremos, probablemente vinculados al pluriempleo o autoempleo intensivo.

Ejercicio 5)


	2004	2024	TOTAL
Cantidad de observaciones	2848	2836	5684
Cantidad de observaciones con Nas en la variable "Estado"	10	0	10
Cantidad de Ocupados	3079	3224	6303
Cantidad de Desocupados	528	311	839
Cantidad de variables limpias y homogeneizadas	178	178	178

El cuadro resume las principales características de la muestra combinada entre las bases de 2004 y 2024. Se observa una distribución equilibrada en la cantidad de observaciones entre ambos años, con un total conjunto de 5.684 registros. La

variable “Estado” presenta muy pocos valores perdidos (10 en total), lo cual indica buena calidad de los datos. Además, se destaca una mayoría de ocupados en ambos años, aunque con una leve disminución en la cantidad de desocupados en 2024 respecto de 2004. Por último, se trabajó con un total de 178 variables limpias y homogeneizadas, garantizando consistencia en el análisis comparativo entre ambos períodos.

Parte II: Métodos No Supervisados


Ejercicio 1)



La matriz de correlaciones para la Región GBA muestra, como era de esperar, una fuerte correlación positiva entre las variables edad y edad2 (0.98), dado que una es función cuadrática de la otra. La variable educ (años de educación) presenta una correlación positiva moderada con el salario semanal (0.23), lo que sugiere que mayores niveles educativos tienden a asociarse con mejores ingresos. Por otro lado, horastrab tiene una correlación baja pero positiva con el salario semanal (0.16), lo que indica que trabajar más horas se relaciona ligeramente con mayores ingresos. Las demás correlaciones son muy débiles, lo que sugiere que, fuera de estas relaciones destacadas, las variables son en gran medida independientes entre sí.


A. PCA

Ejercicio 2)




Este gráfico de dispersión muestra los resultados del Análisis de Componentes Principales (PCA), específicamente el primero y segundo componente principal. La mayoría de las observaciones se agrupan cerca del eje horizontal (Componente Principal 1), con valores del Componente Principal 2 concentrados entre 0 y 5, lo que sugiere que la varianza más significativa está explicada por el primer componente. Se identifican algunos valores atípicos, especialmente uno con un valor muy alto en el Componente 2 (mayor a 30), lo que podría indicar un caso extremo o una observación inusual. En general, el gráfico sugiere una estructura de datos con una clara dirección principal de variabilidad y cierta dispersión limitada en el segundo componente.

Ejercicio 3)



Ejercicio 4)



En la mayoría de los casos, el primer componente tendrá la mayor proporción de varianza explicada, seguido por el segundo componente, y así sucesivamente. Si el primer o primer y segundos componentes explican una gran parte de la varianza, es viable considerar que con pocos componentes se puede captar gran parte de la variabilidad de los datos. Si los componentes posteriores tienen una proporción pequeña, indica que esas dimensiones adicionales no aportan mucha información relevante y podrían ser descartadas para simplificar el modelo.

B. Cluster

Ejercicio 5) a)




Gráfico 1: k = 2

El algoritmo identifica dos grandes grupos.

Es probable que el criterio de segmentación principal esté basado en la Edad, separando quizás personas jóvenes de mayores.

Hay alta heterogeneidad en el eje del Salario, lo que indica que este valor no está siendo completamente captado por el clustering.

Gráfico 2: k = 4

Aparecen subgrupos más definidos, y uno de los clusters (el punto amarillo) probablemente es un outlier con un salario extremadamente alto.

El modelo comienza a capturar mejor la variabilidad en el salario, aunque sigue habiendo solapamiento entre clusters.

Gráfico 3: k = 10

El modelo segmenta más finamente la muestra, detectando más grupos incluso entre rangos cercanos de edad y salario.

Si bien esto permite capturar detalles más sutiles, también corre el riesgo de sobreajustar: algunos clusters pueden representar pequeñas variaciones no relevantes o incluso ruido.


Conclusión general:

A medida que k aumenta, el modelo gana en granularidad pero también puede perder interpretabilidad y generalización.

Un análisis del inercia intra-cluster o el uso del método del codo o silhouette score ayudaría a definir un k óptimo.


El outlier del salario aparece de forma marcada en todos los casos; sería conveniente tratarlo previamente o evaluar su influencia en el agrupamiento.

Ejercicio 5) b)



En el gráfico se observan los resultados del clustering con K-Means para k=2, utilizando las variables edad y educación como predictores, y diferenciando visualmente entre personas ocupadas y desocupadas mediante colores. Aunque el algoritmo formó dos grupos con centroides bien definidos —uno correspondiente a personas con menor nivel educativo y mayor edad promedio, y otro a personas más jóvenes con mayor educación—, los colores de los puntos (ocupados y desocupados) se encuentran fuertemente mezclados dentro de cada cluster. Esto indica que, al menos con estas dos variables, el algoritmo no logra separar de manera efectiva a las personas según su condición laboral. La distribución de ocupados y desocupados es bastante homogénea en ambos grupos, lo que sugiere que ni la edad ni la educación, por sí solas, son suficientes para discriminar entre estos dos estados. Para una clasificación más precisa, probablemente sería necesario incorporar otras variables más relacionadas directamente con el empleo, como salario, horas trabajadas o estado civil.

Ejercicio 6)



Trabajo práctico N°3

Un dendograma es una representación visual de un árbol jerárquico que muestra cómo los clusters se agrupan. En el dendograma, cada hoja representa un punto de datos y los nodos representan las combinaciones de puntos o clusters. La altura de los nodos indica la distancia (o disimilitud) entre los clusters que se están uniendo. Cuanto mayor sea la distancia, más disímiles son los grupos. Es una excelente herramienta para visualizar cómo se forman los clusters a medida que avanzamos en el proceso de agrupamiento.