

BIG DATA & MACHINE LEARNING

MÉTODOS SUPERVISADOS: REGRESIÓN & CLASIFICACIÓN USANDO LA EHP

Equipo 23: Francisco Borghetti, Brian Rios, Leandro Mariniello

A. Enfoque de validación 2

 Punto 1..... 2

B. Método supervisado 1: Modelo de regresión lineal 3

 Punto 2..... 3

 Punto 3..... 3

 Punto 4..... 4

C. Método de clasificación y performance..... 6

 Punto 5..... 6

 Punto 6..... 7

A. Enfoque de validación

Punto 1

Año 2004

Las diferencias de medias entre ambos subconjuntos son, en general, bajas y sin patrones sistemáticos de sesgo, lo que sugiere un correcto muestreo aleatorio. Las variables con mayores diferencias absolutas, como PP11D_COD y PP04D_COD, presentan diferencias menores al 1,2% respecto de sus medias (≈ 500 unidades sobre medias cercanas a 50.000), lo cual es estadísticamente aceptable en contextos con varianzas elevadas.

El comportamiento de variables como P21, CH15_COD o ITF también se mantiene estable entre ambos subconjuntos, confirmando que la representatividad de las distribuciones originales se preserva en la división, requisito clave para evitar problemas de sobreajuste o pérdida de generalización del modelo.

Año 2024

En este caso, se observa una mayor heterogeneidad en las diferencias de medias, aunque esto es esperable dado que varias variables (ITF, IPCF, P47T, entre otras) presentan una alta dispersión, con desvíos estándar del orden de cientos de miles. Aun así, las diferencias absolutas entre medias en la mayoría de los casos no superan el 10% relativo respecto de sus medias de entrenamiento, y no hay evidencia de un sesgo sistemático. Algunas diferencias relativamente altas (como en V10_M o T_VI) deben interpretarse en el contexto de sus elevadas varianzas y la naturaleza posiblemente atípica de sus distribuciones (concentraciones en torno a cero y colas largas).

Cabe destacar que el comportamiento de variables relevantes como PP11D_COD o PP04D_COD se mantiene bastante estable también en 2024, lo cual brinda garantías adicionales sobre la validez del split en un contexto de mayor varianza y complejidad estructural.

B.Método supervisado 1: Modelo de regresión lineal

Punto 2

Modelo	edad	edad2	educ	mujer	tiene_cobertura	sabe_leer_escribir	N	R2
(1)	0.025*** (0.00)	NA	NA	NA	NA	NA	3472	0,011
(2)	0.086*** (0.02)	-0.001** (0.00)	NA	NA	NA	NA	3472	0,013
(3)	0.088*** (0.02)	-0.001** (0.00)	0.327*** (0.01)	NA	NA	NA	3472	0,299
(4)	0.068*** (0.02)	-0.000** (0.00)	0.250*** (0.01)	3.139*** (0.11)	NA	NA	3472	0,437
(5)	0.077*** (0.01)	-0.001*** (0.00)	0.165*** (0.01)	1.758*** (0.09)	3.776*** (0.08)	0.265 (0.45)	3471	0,646

Se observa una mejora progresiva en el poder explicativo de los modelos a medida que se incorporan variables adicionales.

- **El Modelo (1)**, que sólo incluye edad, explica apenas un 1,1% de la varianza del salario.
- **El Modelo (2)** mejora marginalmente con la inclusión de edad².
- **A partir del Modelo (3)**, al incluir el nivel educativo, el R2R^2R2 aumenta significativamente a 0.299, lo que indica que la educación es una variable altamente explicativa del salario semanal.
- **El Modelo (4)** incorpora una dummy de mujer, con un coeficiente positivo y significativo, lo cual puede estar capturando diferencias asociadas a género (aunque la interpretación depende de cómo se codificó la variable).
- **El Modelo (5)**, que suma cobertura médica y alfabetización (sabe_leer_escribir), alcanza un R2R^2R2 de 0.646, mostrando la mejor capacidad explicativa entre todos los modelos. Esto indica que la inclusión de variables relevantes relacionadas con el capital humano mejora considerablemente la predicción del salario.

En conclusión, la calidad del modelo mejora sustancialmente al incorporar variables que capturan mejor las diferencias en características individuales relevantes para el salario.

Punto 3

Modelo	MSE (×1e12)	RMSE	MAE	Error Relativo (%)	R²_test	N_test
(1)	0.02	\$146,968	\$79,341	100.1%	-0.354	1481
(2)	0.02	\$146,903	\$79,332	100.1%	-0.353	1481
(3)	0.02	\$136,071	\$74,318	93.7%	-0.160	1480
(4)	0.02	\$128,174	\$66,545	83.9%	-0.029	1480
(5)	0.04	\$196,794	\$96,515	121.7%	-1.426	1480


Los resultados muestran una clara mejora en la capacidad predictiva de los modelos hasta el Modelo (4), con una disminución progresiva en las métricas de error (MAE, RMSE, Error Relativo) y una mejora del R2R^2R2 en testeo.

- **Modelos (1) y (2)** presentan exactamente el mismo rendimiento, lo que sugiere que la inclusión de edad² no aporta valor predictivo significativo sobre testeo en relación con la edad sola.
- **El Modelo (3)** mejora notablemente, especialmente en MAE y RMSE, lo cual está asociado a la incorporación de la variable educativa (educ), una de las más relevantes para explicar salarios.
- **El Modelo (4)** logra el mejor desempeño general: reduce todos los errores y se acerca a un R2R^2R2 test cercano a cero, lo cual, aunque aún bajo, indica una mejor adaptación al patrón de testeo.

- **El Modelo (5)**, sin embargo, sufre una clara sobreajuste (overfitting): aunque en entrenamiento fue el más potente (ver R^2 en el punto 2), en testeo su rendimiento cae abruptamente, con el mayor MAE, el mayor RMSE, un error relativo de 121.7%, y un R^2 fuertemente negativo (-1.426). Esto sugiere que las variables adicionales incluidas (como sabe_leer_escribir y tiene_cobertura) no generalizan bien sobre nuevas observaciones.

En conclusión, el Modelo (4) parece ser el mejor equilibrio entre capacidad explicativa y generalización fuera de muestra, mientras que el Modelo (5) demuestra que más variables no siempre implican mejor desempeño predictivo, especialmente si se incurre en sobreajuste.

Punto 4



Aquí se presenta un gráfico de dispersión que compara los salarios semanales reales contra las predicciones del Modelo (4) (El de mejor desempeño según los resultados del punto anterior) en función de la edad. Se utiliza la base de testeo, diferenciando por sexo (según la variable mujer), e incluyendo la curva de tendencia de las predicciones.

El mismo muestra la distribución de salarios reales (colores rojo y azul para mujeres y hombres, respectivamente) en relación con la edad, junto a la tendencia de las predicciones del modelo (línea verde). Se observan varias cuestiones destacables:

La curva predicha sigue una forma parabólica invertida, coherente con la inclusión de los términos edad y edad² en el modelo. Esto sugiere que los salarios estimados tienden a crecer con la edad hasta un punto máximo (aproximadamente entre los 45 y 50 años), para luego comenzar a descender.

Existe una notable dispersión en los datos reales, especialmente en edades productivas (30-60 años), con muchos valores extremos (outliers) que el modelo no logra capturar. Esto es esperable en regresiones lineales simples, donde el modelo predice el valor esperado del salario, pero no sus extremos.

También se nota un piso en las predicciones en torno a valores muy bajos o nulos de salario, posiblemente por casos sin ingresos registrados o mal reportados. Esta limitación podría afectar el MAE y el R^2 en testeo.

Trabajo práctico N°4

La curva de predicción tiene buena coherencia estructural, aunque su capacidad de ajuste a las variaciones individuales de los datos reales es limitada, lo cual se refleja en el valor relativamente bajo de R^2 en testeo.

En resumen, el Modelo (4) logra capturar razonablemente la tendencia general del salario en función de la edad, aunque con errores considerables en la predicción individual debido a la alta dispersión del fenómeno.

C. Método de clasificación y performance

Punto 5

Se implementaron dos modelos de clasificación binaria sobre la base de datos de ocupados para los años 2004 y 2024:

- Regresión logística (Logit)
- K-Nearest Neighbors (KNN) con K = 5

Ambos modelos fueron entrenados sobre la base de entrenamiento correspondiente a cada año, y luego evaluados sobre la base de testeo. A continuación se reportan las métricas de desempeño: matriz de confusión (con umbral de clasificación $p > 0.5$), valores de AUC, accuracy y la curva ROC correspondiente.

Modelo: KNN 2024	Modelo: Logit 2024	Modelo: KNN 2004	Modelo: Logit 2004
Matriz de Confusión:	Matriz de Confusión:	Matriz de Confusión:	Matriz de Confusión:
[[2003 7]	[[2006 4]	[[2113 21]	[[2134 0]
[91 2]]	[89 4]]	[150 8]]	[65 93]]
AUC: 0.7041	AUC: 0.8018	AUC: 0.6248	AUC: 0.9115
Accuracy: 0.9534	Accuracy: 0.9558	Accuracy: 0.9254	Accuracy: 0.9716

En ambos años, el modelo de regresión logística (Logit) mostró un desempeño superior al de KNN según todas las métricas:

- Mayor AUC, lo que indica mejor capacidad de discriminación entre clases.
- Mayor accuracy, reflejando una mejor tasa global de predicciones correctas.
- Matriz de confusión más equilibrada, especialmente en la identificación de positivos (última fila), donde KNN tiene un desempeño pobre.


En particular:

- **En 2004**, Logit logra distinguir correctamente 93 casos positivos con 0 falsos positivos, frente a los solo 8 verdaderos positivos de KNN y 21 falsos positivos.
- **En 2024**, aunque ambos métodos enfrentan una reducción general en performance, Logit sigue superando a KNN, tanto en AUC como en accuracy.

El modelo KNN sufre especialmente en sensibilidad (recall), es decir, identifica muy pocos verdaderos positivos. Esto puede deberse a la naturaleza discreta y no paramétrica del método, que resulta menos eficiente cuando los datos presentan alta dimensionalidad o clases desbalanceadas.

La curva ROC (ver gráfico abajo) refuerza esta conclusión: las curvas de Logit se mantienen consistentemente por encima de las de KNN para ambos años, con áreas bajo la curva considerablemente mayores.

En conclusión, El modelo de regresión logística (Logit) es claramente superior al modelo de KNN tanto en 2004 como en 2024. Presenta mayor capacidad de discriminación entre clases, mejor precisión general y menor tasa de error en la clasificación de los casos positivos.



Punto 6

Luego de seleccionar el modelo de mejor desempeño (Regresión Logística 2004) en el análisis anterior, procedimos a utilizarlo para predecir la situación laboral de las personas de la base norespondieron.

Resultados de predicción:

Modelo utilizado: Logit 2004

- Total de personas analizadas: 51
- Número predicho como desocupadas: 2
- Proporción de desocupación estimada: 3.92%

Para tener una segunda referencia, también se utilizó el modelo KNN 2024, obteniéndose el mismo resultado:

Modelo utilizado: KNN 2024

- Número de desocupados predichos: 2 sobre 51 personas
- Proporción estimada: 3.92%

Ambos modelos coinciden en identificar a 2 personas como potencialmente desocupadas dentro del grupo de no respondientes, lo que representa un porcentaje bajo (menos del 4%). Este resultado sugiere que la mayoría de las personas que no respondieron probablemente no presentan características similares a las personas desocupadas en la base de entrenamiento.

El uso de modelos predictivos permite generar inferencias sobre poblaciones sin información directa, aunque es importante destacar que estas estimaciones están sujetas a los supuestos del modelo y a la calidad de las variables observadas.